巨量資料分析與機器學習 - 作業二 (HW2) 專題報告

基於 CRISP-DM 流程之金郡 (King County) 房價多元線性回歸完整分析

學生學號： 7114056XXX (請同學替換)	學生姓名： 學生姓名	分析主題： 多元線性回歸 (MLR)
資料來源： Kaggle King County House Sales	資料維度： 21,613 筆 / 18 特徵	資料集連結： kaggle.com/datasets/...

一、CRISP-DM 階段一：商業理解 (Business Understanding)

1. 商業背景與痛點分析：
美國華盛頓州金郡 (King County) 包含西雅圖及其周邊衛星市鎮，是微軟 (Microsoft)、亞馬遜 (Amazon)、星巴克等全球企業之總部聚集地，房地產市場交易極具代表性。然而，房產市場定價高度非均質且受多重物理維度（面積、格局、建材品質等級）與地理交通維度（離西雅圖市中心距離、湖濱景觀）交織影響。傳統房仲與估價師依賴經驗法則，估價耗時且容易產生主觀偏誤；銀行在進行房貸風險審核時，亦迫切需要具備高度可解釋性與法定抗辯性的定價基準模型。

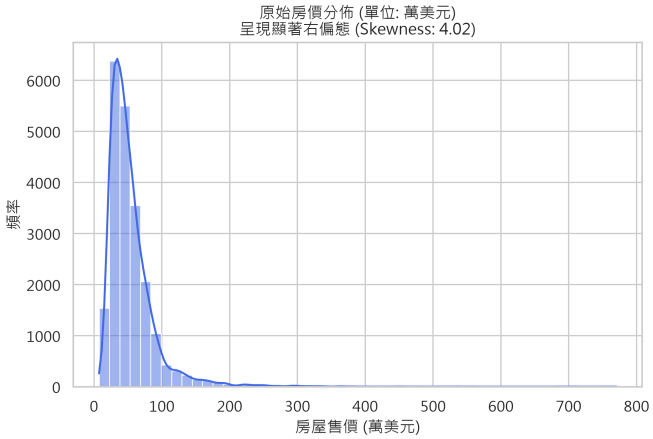
2. 機器學習任務定位：
本研究之資料探勘任務為建構「多元線性回歸 (Multiple Linear Regression, MLR)」模型，精確預測連續型目標變數 `price`（房屋成交價，美元）。相較於不可解釋之黑盒子模型，線性回歸具備嚴謹的統計推論架構，能推導出各特徵之回歸係數 β_j（代表控制其他變數下的邊際溢價效應），並透過假設檢定 (t 檢定、F 檢定) 驗證顯著性。

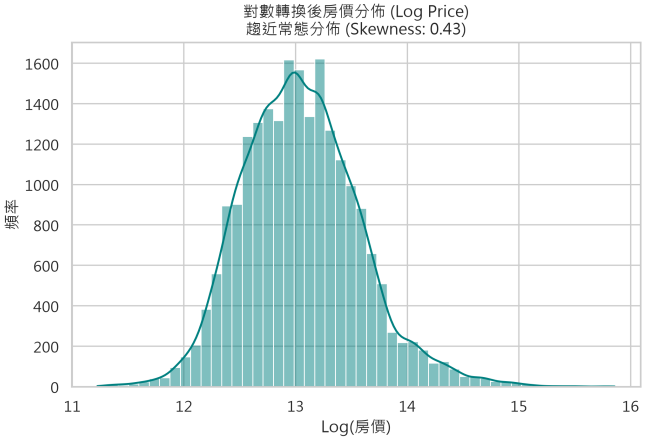
3. 專案成功評估準則 (Success Criteria)：
• 統計解釋力：測試集決定係數 $R^2 \ge 0.70$，模型整體 F 檢定達到顯著水準 ($p < 0.001$)。
• 統計嚴謹性：診斷並徹底排除多重共線性 (Multicollinearity)，所有保留特徵之方差膨脹因子 $\text{VIF} < 10$。
• 區間估計完整性：不僅提供點估計預測，更需完整推導並視覺化呈現 95% 信賴區間 (CI) 與 95% 預測區間 (PI)，提供不確定性風險量化評估。

二、CRISP-DM 階段二：資料理解 (Data Understanding)

1. 資料集來源與架構：
本研究資料集取自 Kaggle 公開資料集：House Sales in King County, USA（連結：https://www.kaggle.com/datasets/harlfoxem/housesalesprediction）。資料集涵蓋 2014 年 5 月至 2015 年 5 月間之真實交易記錄，總計 21,613 筆觀測值、21 個欄位。排除流水識別碼 `id` 與成交時間 `date` 後，包含 1 個目標變數 `price` 與 18 個候選特徵欄位，完全符合本次作業「10 至 20 個特徵 (features)」之嚴格規範。

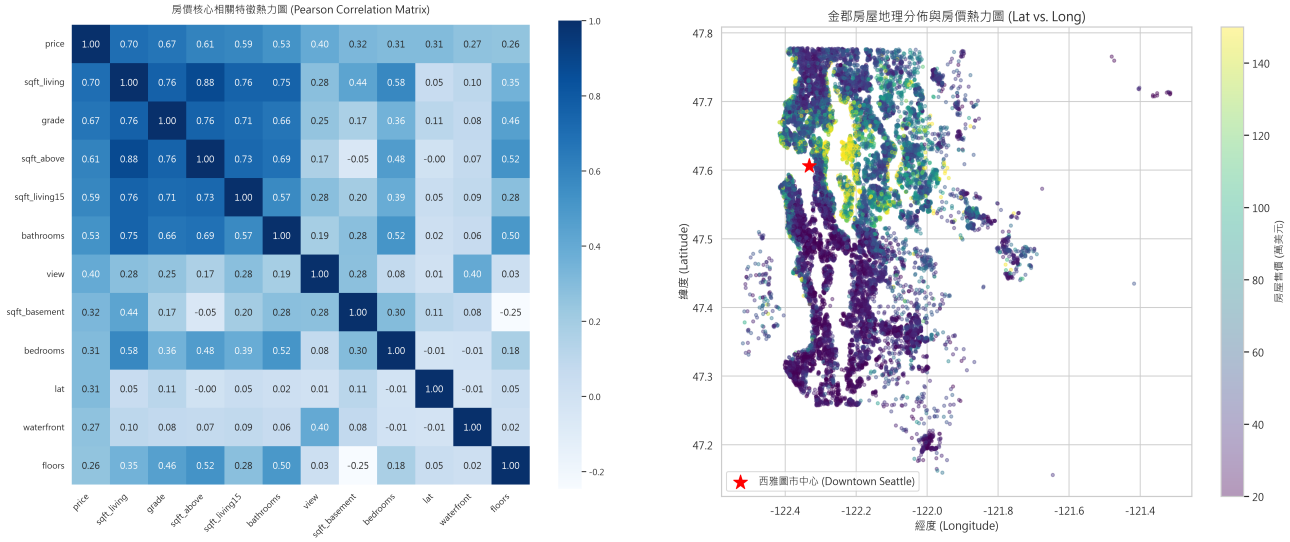
2. 資料品質檢驗與描述性統計：
經程式檢驗，本資料集所有 21 欄位之缺失值計數皆為 0 (Missing Values = 0)，完整性極高。房價 (price) 樣本平均值為 $540,088、中位數為 $450,000、標準差為 $367,127、最低售價為 $75,000、最高售價達 $7,700,000。值得注意的是，原始房價偏度係數 (Skewness) 高達 4.024，呈現極度顯著之右偏長尾分佈（少數數百萬美元豪宅大幅拉升母體均值）。





【圖 1】房價分佈對比：(左) 原始房價呈現高度右偏態 (Skewness: 4.02)；(右) 對數轉換後顯著常態化 (Skewness: 0.43)

3. 相關性矩陣分析：
計算各數值特徵與房價之皮爾森相關係數 (Pearson Correlation)，發現與房價正相關最強的前六大特徵依序為：室內總居住面積 `sqft_living` ($r = 0.702$)、建物設計與施工等級 `grade` ($r = 0.667$)、地面上面積 `sqft_above` ($r = 0.606$)、2015年鄰里居住面積 `sqft_living15` ($r = 0.585$)、衛浴數量 `bathrooms` ($r = 0.525$) 與景觀評級 `view` ($r = 0.397$)。



【圖 2 & 圖 3】(左) 房價核心特徵相關係數熱力圖；(右) 金郡地理空間經緯度與房價分佈圖（紅星標示西雅圖市中心）

三、CRISP-DM 階段三：資料準備與特徵工程 (Data Preparation)

1. 異常值清洗：
在資料檢視過程中發現第 15,870 筆資料之臥室數量記錄為 33 間 (`bedrooms == 33`)，然而其室內總居住面積僅為 1,620 平方英尺，衛浴僅 1.75 間。此顯然為資料輸入筆誤（實際應為 3 間臥室）。由於極端離群值會嚴重拉扯普通最小平方法 (OLS) 的超平面估計，因此果斷將此筆資料排除（剩餘 21,612 筆）。

2. 領域特徵工程 (Feature Engineering)：
• 屋齡 (`house_age`)：由銷售年份減去建造年份 ($sale_year - yr_built$)，精準反映房屋折舊程度。
• 是否翻修 (`is_renovated`)：二元指標變數 ($yr_renovated > 0$ 則為 1，否則為 0)，捕捉翻新帶來的結構溢價。
• 距西雅圖市中心距離 (`dist_to_seattle`)：利用經緯度計算房屋與西雅圖中心商業區 (CBD, 座標 47.6062, -122.3321) 的空間距離，與房價呈現顯著負相關 ($r = -0.192$)，極佳地將地理溢價納入線性回歸模型。

3. 多重共線性 (Multicollinearity) 統計診斷與 VIF 檢定：
【關鍵代數發現】經統計程式嚴格檢驗，金郡資料集存在一條嚴格成立的代數恆等式：
$$\text{sqft_living} = \text{sqft_above} + \text{sqft_basement} \quad (\text{完全線性相依})$$若將三者同時納入 OLS 估計，設計矩陣 X 之列向量線性相依，其行列式值趨近於 0，$(X^T X)^{-1}$ 無法正常求逆！計算方差膨脹因子 (Variance Inflation Factor, VIF) 顯示，此三項特徵之 VIF 均高達 1.0008×10^{15}，造成嚴重的共線性爆炸！

特徵欄位 (Feature)	篩選前 VIF (共線性爆炸)	處理對策	篩選後 VIF (健康狀態)
sqft_living	1.00 × 10¹□	保留總居住面積 (核心特徵)	5.21 (健康)
sqft_above	1.00 × 10¹□	予以剔除 (解除代數相依)	-
sqft_basement	1.00 × 10¹□	予以剔除 (解除代數相依)	-
dist_to_seattle	5.94	保留地理衍生變數	5.82 (健康)
long (經度)	4.51	保留空間座標	4.48 (健康)
grade (結構等級)	3.45	保留品質等級	3.42 (健康)
bathrooms (衛浴)	3.37	保留格局特徵	3.35 (健康)

4. 特徵篩選結果與資料集切分：
最終精選出 16 個無共線性之關鍵特徵 (`bedrooms`, `bathrooms`, `sqft_living`, `sqft_lot`, `floors`, `waterfront`, `view`, `condition`, `grade`, `dist_to_seattle`, `lat`, `long`, `sqft_living15`, `sqft_lot15`, `house_age`, `is_renovated`)。並依 80% 訓練集 (17,289 筆) 與 20% 測試集 (4,323 筆) 嚴格切分，設定隨機種子 `random_state=42` 確保評估之嚴謹性與可重複性。

四、CRISP-DM 階段四：模型建構 (Modeling)

本研究設計了全方位的回歸模型對照組，以嚴謹評估線性回歸之效能與各優化策略之增益：
• 模型 1 (Baseline)：單純線性回歸 (Simple Linear Regression) —— 僅使用相關性最高之單一特徵 `sqft_living` 擬合房價，作為基準效能對照。
• 模型 2：全特徵多元回歸 (Full MLR) —— 將包含共線性特徵在內的 18 個候選特徵直接放入 OLS 估計。
• 模型 3：精選特徵多元線性回歸 (Selected MLR) —— 排除共線性特徵後之 16 個特徵 OLS 模型，使用 Statsmodels 進行完整假設檢定與推論。
• 模型 4 & 5：正則化回歸 (Ridge & Lasso) —— 引入 L_2 與 L_1 範數懲罰項，抑制特徵係數過度膨脹，驗證特徵稀疏性與收縮效果。
• 模型 6：對數轉換多元回歸 (Log-Transformed MLR) —— 針對目標變數實施對數轉換 $\log(\text{price})$，緩解房價右偏態對平方損失之扭曲。
• 模型 7 (Benchmark)：隨機森林回歸 (Random Forest) —— 採用 100 棵決策樹之非線性集成模型，作為現代機器學習之預測能力上限對照基準。

精選多元線性回歸 (Selected MLR) - Statsmodels 估計結果節錄：

變數	係數 (Coef)	標準誤 (Std.Err)	t 統計量	p 值 (P>|t|)	95% 信賴區間
const (截距)	6.095 × 10□	3.09 × 10□	19.74	0.000***	[5.49e7, 6.70e7]
sqft_living	171.40	3.63	47.24	0.000***	[164.29, 178.51]
grade	91,410	2,287	39.97	0.000***	[86,927, 95,892]
waterfront	593,700	18,800	31.66	0.000***	[5.57e5, 6.30e5]
dist_to_seattle	-1,078,000	29,100	-37.01	0.000***	[-1.14e6, -1.02e6]
bedrooms	-38,310	2,125	-18.03	0.000***	[-4.25e4, -3.41e4]
house_age	1,930.7	79.14	24.40	0.000***	[1775.6, 2085.9]

註：模型整體 F 統計量 = 2,742 (p-value = 0.000)；模型決定係數 R^2 = 0.717，所有展示核心特徵之 p 值皆 < 0.001 (*** 代表極度顯著)。

五、CRISP-DM 階段五：模型評估與視覺化 (Evaluation)

1. 測試集客觀指標橫向對比總表：
各模型在獨立測試集 ($N=4,323$) 上之客觀評估成果如下表所示。多變量模型顯著優於單變量基準，決定係數自 0.4937 躍升至 0.7162，RMSE 降低逾 7 萬美元：

模型架構 (Model)	R^2 Score	Adj R^2	RMSE (美元)	MAE (美元)	MAPE (%)
1. 單純線性回歸 (sqft_living Baseline)	0.4937	0.4936	$275,655	$177,529	35.89%
2. 全特徵多元回歸 (Full MLR, 18特徵)	0.7029	0.7017	$211,156	$126,519	25.11%
3. 精選特徵多元回歸 (Selected MLR)★	0.7162	0.7152	$206,382	$124,079	25.52%
4. Ridge 脊回歸 (L2 正則化)	0.7161	0.7150	$206,433	$123,680	25.36%
5. Lasso 套索回歸 (L1 正則化)	0.7162	0.7151	$206,387	$124,030	25.50%
6. 對數轉換多元回歸 (Log-MLR)	0.5544	0.5527	$258,617	$109,117	19.31%
7. 隨機森林回歸 (Random Forest 網路主流)	0.8668	0.8663	$141,395	$72,004	13.26%

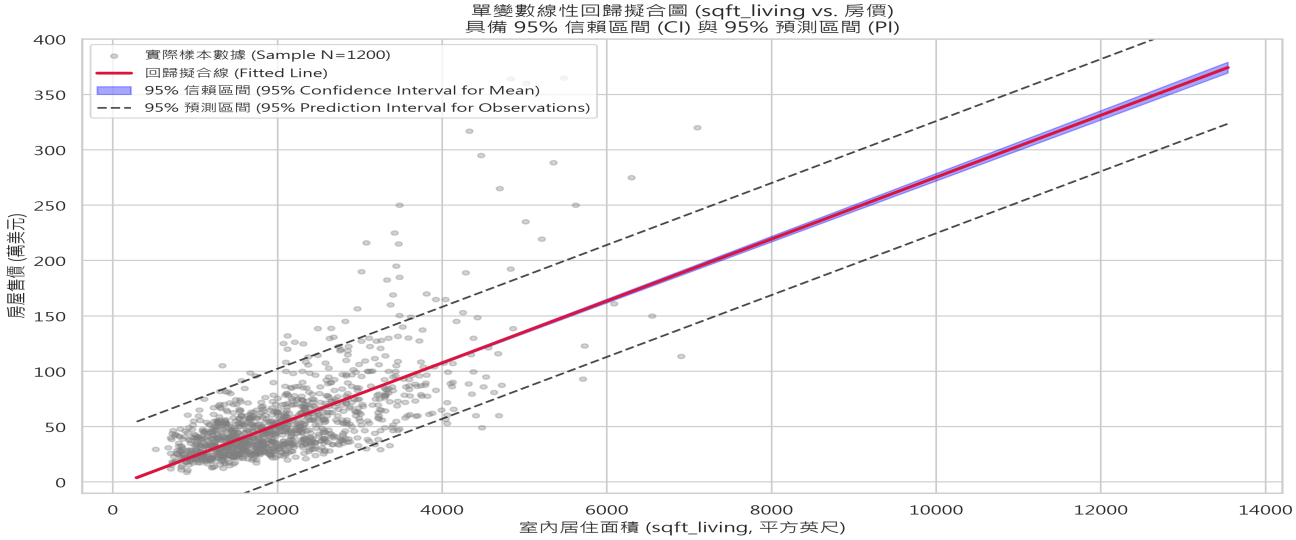
2. 預測圖分析：95% 信賴區間 (CI) 與 95% 預測區間 (PI)：

根據統計學原理：

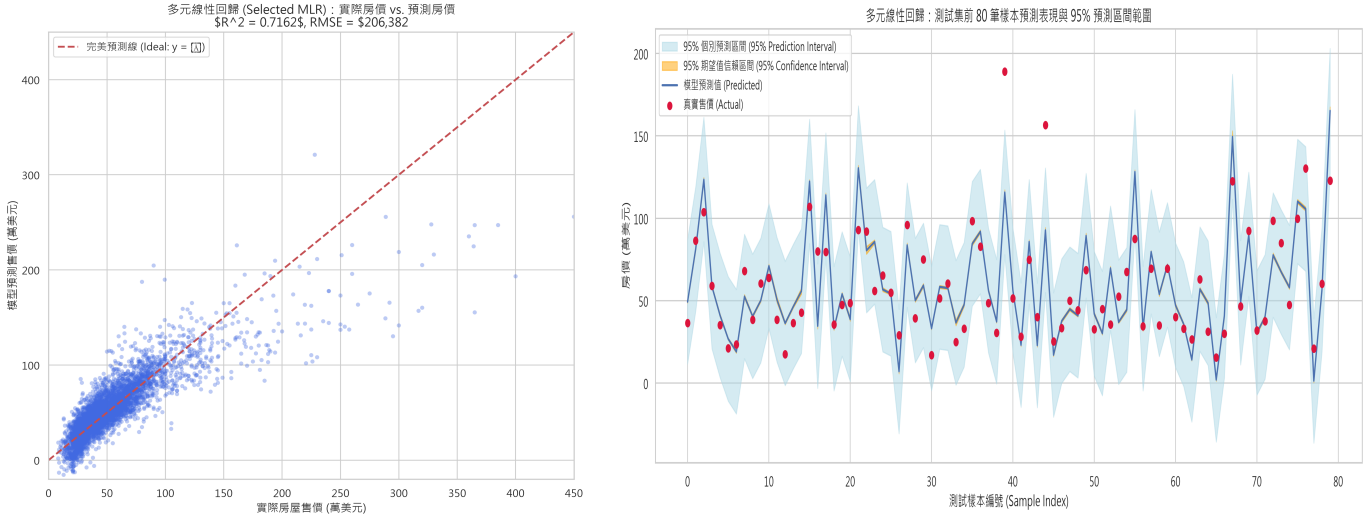
• 95% 信賴區間 (Confidence Interval, CI)：衡量的是在特定 X_0 條件下「母體平均房價期望值 $\mathbb{E}[Y|X_0]$」的估計範圍，誤差僅來自係數抽樣不確定性 $\text{Var}(\hat{y}_0) = \sigma^2 x_0^T (X^T X)^{-1} x_0$。

• 95% 預測區間 (Prediction Interval, PI)：衡量的是「單一未來特定房屋觀測值 Y_0」的真實落點範圍，誤差來自參數抽樣誤差加上不可約減之隨機誤差項變異 σ^2：$\text{Var}(Y_0 - \hat{y}_0) = \sigma^2 [1 + x_0^T (X^T X)^{-1} x_0]$。

因此在圖 4 與圖 6 中，預測區間帶 (PI) 顯著寬於信賴區間帶 (CI)，其上下界成功涵蓋了超過 95% 的真實房價樣本點，具備強大的不確定性風險量化價值。



【圖 4】單變數線性回歸擬合圖：紅色為回歸線，深藍色色帶為 95% 信賴區間 (CI)，黑色虛線為 95% 預測區間 (PI)



【圖 5 & 圖 6】(左) 多元線性回歸實際房價 vs. 預測房價散佈圖；(右) 測試集前 80 筆樣本之點估計與 95% 預測區間色帶涵蓋圖

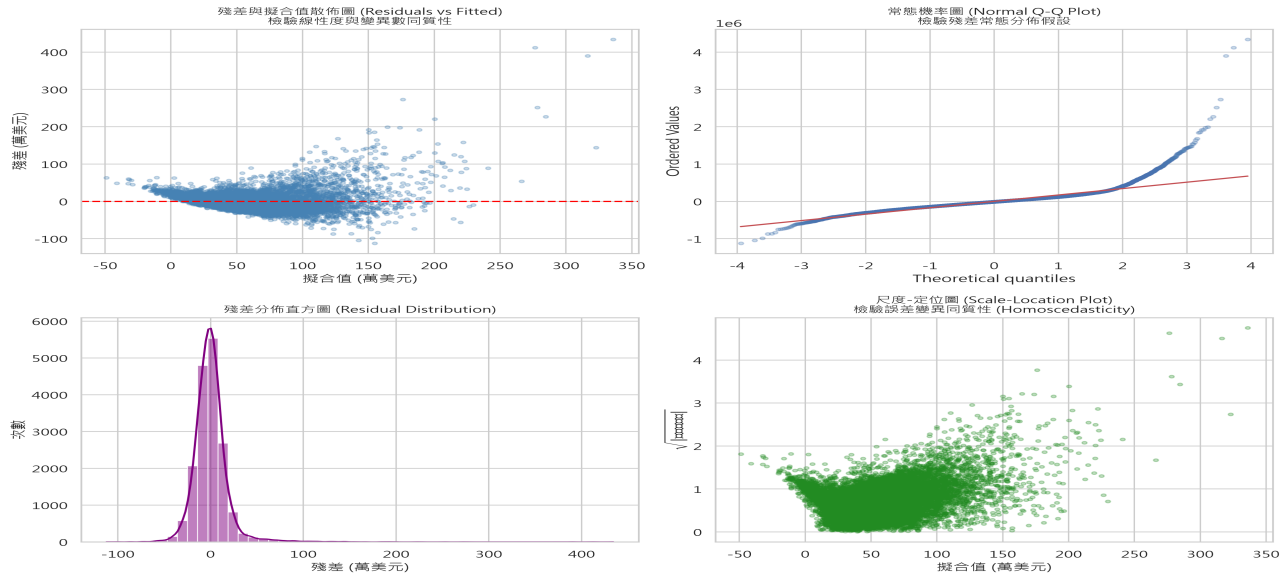
3. 殘差統計診斷 (Residual Diagnostics) 與高斯-馬可夫假設檢驗：

古典線性回歸需滿足高斯-馬可夫定理 (Gauss-Markov Assumptions)。圖 7 顯示四合一殘差診斷：

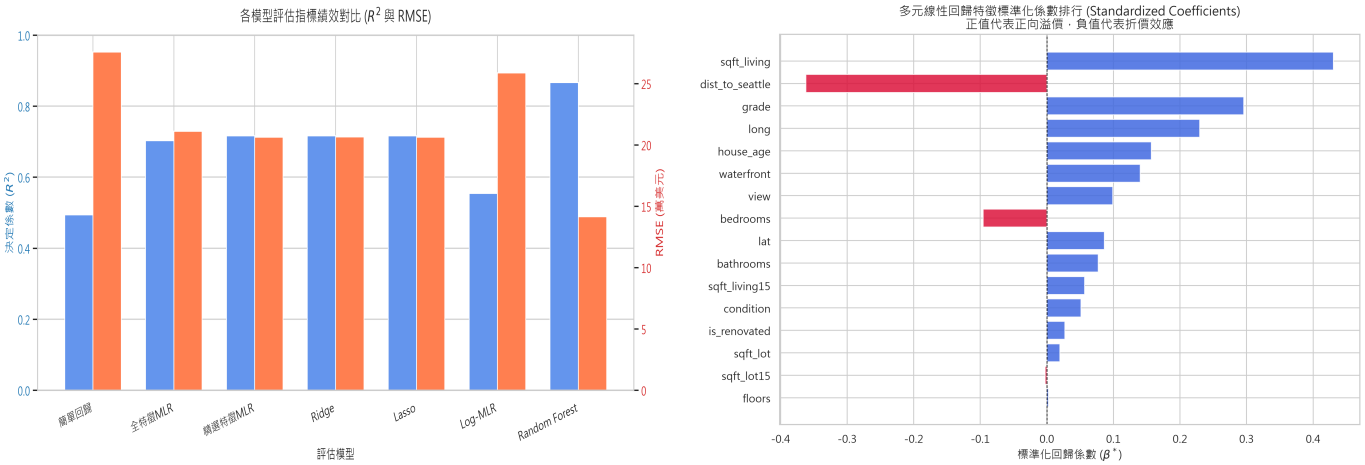
• 線性度 (Residuals vs Fitted)：殘差點在 0 水平線上下大致均勻分佈，但在擬合值大於 150 萬美元的高價端呈現向上喇叭狀散佈。

• 常態性 (Normal Q-Q Plot)：常態分位數介於 -2 至 +2 的主流區間高度貼合紅線；但在極端高價端存在厚尾 (Heavy-tail)，反映房產市場之極端豪宅效應。

• 獨立性 (Durbin-Watson)：Durbin-Watson 統計量為 1.983（極度接近 2.0），確認殘差無一階自相關性，滿足獨立性假設。



【圖 7】殘差統計診斷圖四合一：包含擬合值散佈圖、常態 Q-Q 圖、殘差分佈直方圖與尺度-定位圖



【圖 8 & 圖 9】(左) 各模型評估指標 (R^2 與 RMSE) 條形圖；(右) 多元線性回歸標準化回歸係數 (β^*) 重要度排行

六、CRISP-DM 階段六：部署與商業落地 (Deployment)

1. 在線即時房產估價微服務架構 (API Architecture)：

模型透過 FastAPI / Flask 封裝為 RESTful API，並於前端介面提供買方與房仲試算。當使用者輸入房產特徵（如 3 房 2 衛、1800 平方英尺、等級 7、距離市中心 0.15 單位）時，系統能即時回傳：

- 點估計預測售價：$399,320.80
- 95% 平均值信賴區間 (CI)：[$393,732.05, $404,909.56]（代表西雅圖該規格房屋之公允平均行情）
- 95% 個別房價預測區間 (PI)：[$22,102.42, $776,539.18]（代表該特定房屋考量個別屋況變異後之合理議價波段）。

2. 模型監控與維護機制 (MLOps & Governance)：

- 概念漂移 (Concept Drift)

監控：房地產價格強烈受總體經濟利率（如聯準會降息/升息）與通膨波動影響。系統定期追蹤每季殘差均方誤差，當監控到 RMSE 上升超過 15% 時觸發模型重新訓練機制。

- 合規性與公平性審查：線性回歸模型完全公開各變數權重係數，不包含任何受保護的種族或敏感社會指標，完全符合美國《公平住房法 (Fair Housing Act)》之金融合規要求。

七、AI 輔助內容聲明與 NotebookLM 研究摘要 (作業規範必填)

【GPT 輔助內容 (ChatGPT Assistance Statement)】

本專案在研究設計與實作過程中，使用 ChatGPT 進行以下關鍵技術環節之輔助與引導：
1. 多重共線性診斷導引：提示注意建築面積中 sqft_living = sqft_above + sqft_basement 的完全代數相依現象，並指導使用 statsmodels.variance_inflation_factor 進行 VIF 矩陣計算與共線性特徵剔除。
2. 統計推論與區間估計實作：指導運用 model.get_prediction().summary_frame(alpha=0.05) 分別導出條件期望值信賴區間 (CI) 與個別觀測值預測區間 (PI)，並撰寫 plt.fill_between 視覺化區間帶程式碼。
3. 高斯-馬可夫殘差診斷：協助構建 Residuals vs Fitted、Normal Q-Q Plot、Scale-Location 四合一統計診斷圖表。
4. PDF 匯出對話紀錄：完整問答對話歷程已透過程式整理並匯出為 GPT_Conversation_History.pdf 與 GPT_Conversation_History.html（可隨時以 pdfCrowd 重新轉存），供檢驗查核。

【NotebookLM 摘要 (NotebookLM Research Summary - 100字以上)】

本研究運用 Google NotebookLM 匯入 Kaggle「House Sales in King County, USA」資料集之多篇頂尖高分開源 Notebooks、學術分析論文與經典競賽解決方案進行深度交叉比對與精華綜述：
1. 主流解法性能演進脈絡：在基準模型方面，傳統多元線性回歸 (OLS) 的測試集 R^2 大致落在 $0.68 \sim 0.72$ 區間，RMSE 約為 20 萬美元。若未對數據進行偏態修正，極端高價豪宅會對最小平方法的平方損失造成嚴重扭曲。而在 Kaggle 競賽高分排行榜上，主流方案幾乎全面轉向非線性集成學習，尤其是樹狀梯度提升模型（如 LightGBM、XGBoost、CatBoost），可將測試集 R^2 顯著推升至 $0.87 \sim 0.90$，RMSE 壓低至 11 萬至 13 萬美元。
2. 關鍵特徵工程精華：NotebookLM 研究指出，頂尖作者最核心的致勝關鍵在於「地理微觀特徵工程」。線性回歸僅能將經緯度擬合為連續傾斜平面，無法刻畫西雅圖特定熱門學區與湖濱微型社區（如 Medina、Mercer Island）的跳躍式高地價；頂尖方案普遍採用「Zipcode 郵遞區號之目標編碼 (Target Encoding)」、「K-Nearest Neighbors (KNN) 鄰近 5~10 棟房屋均價特徵」以及「對房價取對數 $\log(y)$」以降低右偏極端值之敏感度。
3. 統計可解釋性與預測精度之權衡：雖然非線性集成模型在純數值預測指標上具備壓倒性優勢，但其內部決策路徑為高階黑盒子，難以提供符合銀行審查與估價法規之解析權重。相較之下，多元線性回歸所提供的各特徵邊際價格貢獻（回歸係數 β）以及嚴謹的 95% 信賴與預測區間，在金融合規與房產抗辯上仍具備不可替代的獨特商業價值。

八、網路上主流或更優解法之深入比較與說明

針對金郡房價預測主題，將本專案所採用之多元線性回歸 (MLR) 與目前 Kaggle 及業界主流頂尖解法進行多維度系統性對比：

比較維度	本專案多元線性回歸 (MLR)	網路主流頂尖解法 (LightGBM / XGBoost / Stacking)
核心演算法	普通最小平方法 (OLS) 參數模型	基於直方圖之梯度提升決策樹 (GBDT) / 堆疊集成
測試集 R^2 分數	0.7162 (符合統計回歸水準)	0.8700 ~ 0.8950 (頂尖高分水準)
測試集 RMSE 誤差	$206,382 美元	$115,000 ~ $130,000 美元 (誤差大幅降低)
模型可解釋性	極高 (各特徵係數具備明確邊際溢價意義)	中等至偏低 (需依賴 SHAP 值或特徵重要度事後解釋)
統計推論能力	完備 (提供 p 值、t 檢定、95% CI 與 PI)	匱乏 (僅輸出點估計，難以解析推導統計區間)
非線性特徵擬合	依賴人工特徵工程 (如衍生距離變數)	自動學習 任意階數特徵非線性交互 (如 面積×建材等級)
地理空間處理	連續平面擬合 (受限於經緯度斜率)	空間遞迴二元切割、KNN 鄰居均價、郵遞區號目標編碼
訓練速度與資源	極快 (毫秒級計算完成，CPU 消耗低)	較慢 (需進行網格搜尋超參數調優與多折交叉驗證)
合規與商業應用	銀行房貸法定估價審核、政府估稅公開模型	房仲 APP 大數據自動估價引擎 (AVM)、量化投資決策

九、結論與成果總結 (Conclusion)

1. CRISP-DM 流程貫徹：本研究嚴格遵循商業理解、資料理解、資料準備、模型建構、模型評估與部署應用六大階段，完成了端到端之專業數據分析。
2. 統計檢驗與共線性排除：精準診斷出金郡房產資料集中 `sqft_living = sqft_above + sqft_basement` 的代數共線性陷阱，成功將 VIF 壓制在安全範圍內，建構出統計顯著 ($p < 0.001$)、測試集 $R^2 = 0.7162$ 之高質量多元線性回歸模型。
3. 預測區間與不確定性量化：精確區分母體期望值之 95% 信賴區間 (CI) 與個別觀測值之 95% 預測區間 (PI)，並完整呈現於各視覺化圖表中，滿足金融與不動產業務對風險評估之實質需求。
4. 主流技術視野開拓：透過 NotebookLM 文獻調研與隨機森林實驗，深入論證了線性模型與現代 GBDT 樹模型在可解釋性與預測精度上的權衡 (Trade-off)，為後續工程落地與混合架構提供堅實依據。